新冠病毒全基因组分析流程说明书

这个流程参考artic分析流程，适用于Nanopore平台新冠全基因组扩增子测序分析流程。除了可以和artic一样在已知引物文件时指定引物bed文件外，还可以在未知引物位置时，通过两端进行固定值的trim来尽可能的消除引物带来的影响。整个流程使用snakemake来进行控制，可以输出新冠基因组的深度覆盖图、一致性全基因组序列、pangolin分型、变异列表和包含上述信息的一个pdf报告。

安装

使用之前**必需安装conda**，整个流程依赖于conda进行软件安装和管理

方法1：

```
wget https://github.com/aadali/artic-like/archive/refs/heads/master.zip
unzip master.zip
mv artic-like-master artic-like
cd artic-like
conda env create -f artic-like.env.yaml # 创建artic-like环境
sudo apt install texlive-binaries   # 安装texlive
```

方法2：

```
git clone https://github.com/aadali/artic-like.git
cd artic-like
conda env create -f env/artic-like.env.yaml # 创建artic-like环境
sudo apt install texlive-binaries   # 安装texlive
```

注：如果使用第一种方法安装，zip压缩包不要在windows或者U盘中进行解压，因为windows系统中解压出来的文件会丢失软texlive文件中一些可执行文件的软连接信息，导致在Ubutu下不能正常使用。可以通过windows或者u盘拷贝zip压缩文件到Ubuntu系统中，unzip后进行操作。

这个过程conda会新建一个名为`artic-like`的新环境，**安装完成后，重启一下终端**，`conda activate artic-like`即可使用

使用

使用之前首先要激活`artic-like`环境，然后用 snakemake 来控制分析流程。该流程在Ubuntu20.04上以及win10的Ubuntu子系统上测试过。

1. 一致性序列

```
snakemake consensus --cores all --config input_fastq=the/path/to/fastq  # --cores all指定所有线程进行分析，也可以写作 --cores 12 或者 --cores 8，指定12个或者8个线程分析。cores必需指定
```

即可进行分析，在当前文件夹下输出`test001`文件夹，并在`test001`下输出另外一个包含所有结果的`test001`文件夹，在`test001/test001/consensus`中即可找到一致性序列，其中`test001`和输出文件夹所在目录可以在`config/config.yaml`中通过修改`analysis_name`来进行指定，也可以在命令行中进行修改，见文件说明。

2. 注释

```
snakemake annotate --cores all --config input_fastq=the/path/to/fastq
```

3. 报告

```
snakemake report --cores all --config input_fastq=the/path/to/fastq
```

这一步可以在`test001/test001/reprot`中输出`test001.report.pdf`报告。

文件说明

artic-like文件夹中包含文件如下：

```
.
├── config
│   ├── config.yaml
│   └── snpEff.config
├── env
│   ├── artic-like.env.yaml
│   └── artic-like.env.yaml.bak
├── genome
│   ├── african_swine_fever_virus
│   ├── hbv
│   ├── ibv_victoria
│   ├── ibv_yamagata
│   ├── influenza_a_virus_california_h1n1
│   ├── influenza_a_virus_shanghai_h7n7
│   ├── poliovirus
│   ├── prrsv
│   └── sars-cov-2
├── readme
│   ├── artic-like-analysis-pipeline.md
│   ├── artic-like-analysis-pipeline.pdf
│   ├── artic-like.directory.png
│   ├── output_directorys.png
│   └── snpEff.genome.config.png
├── scripts
│   ├── nano_filt_vcf.py
│   ├── nano_handle_snpeff_results.py
│   ├── nano_mask_reference.py
│   ├── nano_plot.py
│   ├── nano_report.py
│   ├── nano_trim_align.py
│   └── nano_trim_primer_DISCARDED.py
├── Snakefile
└── texlive
    ├── 2021
    ├── fonts
    └── texmf-local
```

config

1. `config.yaml` 为分析流程中的配置参数，参数如下：

   - `input_fastq` **待分析的数据所在的绝对路径，接受文件夹或者文件。如果是文件夹，可以分为两种情况，1). 文件夹中可以包含若干个包含fastq文件的子文件夹，类似与nanopore测序平台中输出的fastq_pass文件夹中包含多个barcode文件夹，文件结构如下：**

     ```
     test_data/
     ├── barcode01
     ├── barcode03
     └── barcode06
     ```

     此时会在输出 `${analysis_name}` 文件夹下边分别输出以input_fastq下子文件夹名称命名的文件夹，每个样本的分析结果输出在对应的文件夹下。

     2). 文件夹中知己包含fastq序列，文件结构如下：

     ```
     total 9.7M
     3.2M -rw-rw-r-- 1 a a 3.2M 3月  25 20:39 FAT25687_pass_barcode10_0342fc55_0.fastq.gz
     3.3M -rw-rw-r-- 1 a a 3.3M 3月  25 20:39 FAT25687_pass_barcode10_0342fc55_1.fastq.gz
     3.3M -rw-rw-r-- 1 a a 3.3M 3月  25 20:39 FAT25687_pass_barcode10_0342fc55_2.fastq.gz
     ```

   - `primer_bed` **如果有引物信息可以指定引物文件所在位置，如果没有忽略即可。primer_bed文件无需标题行，4列，以tab建分隔。第一列：染色体号；第二列：引物起始位置，base-0；第三列：引物终止位置，base-0；第四列：引物名称，以 `_LEFT` 或者 `_RIGHT` 结尾，用于表示上游和下游引物，每对引物的前缀必需一致,用于表示为一对引物;第五列为引物池名称，是1或者2；第六列指定正链（+）或反链（-）。最后两列在该流程中可有可无，如果要用于artic流程，则需要加上第5列。引物信息格式如下：**

     ```
     1 NC_045512.2     30      54      SARSCoV-1200_1_LEFT     1       +
     2 NC_045512.2     1183    1205    SARSCoV-1200_1_RIGHT    1       -
     3 NC_045512.2     1100    1128    SARSCoV-1200_2_LEFT     2       +
     4 NC_045512.2     2244    2266    SARSCoV-1200_2_RIGHT    2       -
     5 NC_045512.2     2153    2179    SARSCoV-1200_3_LEFT     1       +
     6 NC_045512.2     3235    3257    SARSCoV-1200_3_RIGHT    1       -
     7 NC_045512.2     3144    3166    SARSCoV-1200_4_LEFT     2       +
     8 NC_045512.2     4240    4262    SARSCoV-1200_4_RIGHT    2       -
     9 NC_045512.2     4167    4189    SARSCoV-1200_5_LEFT     1       +
     10 NC_045512.2    5337    5359    SARSCoV-1200_5_RIGHT    1       -
     11 NC_045512.2    5257    5286    SARSCoV-1200_6_LEFT     2       +
     12 NC_045512.2    6358    6380    SARSCoV-1200_6_RIGHT    2       -
     13 NC_045512.2    6283    6307    SARSCoV-1200_7_LEFT     1       +
     14 NC_045512.2    7379    7401    SARSCoV-1200_7_RIGHT    1       -
     15 NC_045512.2    7298    7328    SARSCoV-1200_8_LEFT     2       +
     16 NC_045512.2    8363    8385    SARSCoV-1200_8_RIGHT    2       -
     17 NC_045512.2    8253    8282    SARSCoV-1200_9_LEFT     1       +
     18 NC_045512.2    9378    9400    SARSCoV-1200_9_RIGHT    1       -
     19 NC_045512.2    9303    9327    SARSCoV-1200_10_LEFT    2       +
     20 NC_045512.2    10429   10451   SARSCoV-1200_10_RIGHT   2       -
     21 NC_045512.2    10343   10370   SARSCoV-1200_11_LEFT    1       +
     22 NC_045512.2    11447   11469   SARSCoV-1200_11_RIGHT   1       -
     23 NC_045512.2    11372   11394   SARSCoV-1200_12_LEFT    2       +
     24 NC_045512.2    12538   12560   SARSCoV-1200_12_RIGHT   2       -
     25 NC_045512.2    12450   12473   SARSCoV-1200_13_LEFT    1       +
     ```

     jclife扩增的引物应使用 `${artic-like-directory}/genome/sars-cov-2/jc-1200-primers.bed`

- `trim_bases` 引物信息未知时，bam文件中alignment两端需要trim掉的碱基数(**不是从read两端trim**)，指定 `primer_bed` 后该参数无效，默认25
- `min_read_len` read长度小于该值时，会去掉该read

- `max_read_len` read长度大于该值，会去掉该read
- `min_read_qual` read质量值小于该值，会去掉该read
- `min_mapq` map质量值小于该值时，alignment会被去掉
- `analysis_name` **样本名称，输出文件夹的名称，以及各种输出文件的前缀**
- `what_sample` **是哪种类型的样本，必需是`genome`文件夹下的一个，后续可以通过在`genome`文件夹下增加新的病毒类型比如`hbv`等，用于后续分析样本类型扩展。**
- `model` medaka用到的model参数
- `min_dp` 最小深度，小于这个深度时，一致性序列该位置设定为N
- `min_qual` 变异位点质量值小于该值会被过滤掉，生成的一致性序列中该位点为N
- `het_site` 针对杂合位点，怎样处理。如果het_site为"more"，则一致性序列中该位点为深度较高的allele。如果het_site为“N”，则所有杂合位点都设置为N，**暂时未使用**
- `min_overlap` bam文件中trim掉引物之后或者trim掉固定长度之后，最小的比对长度，小于该值则这条alignment会被去掉。建议RAD或者RBK试剂盒时，设为400; LSK试剂盒1200扩增设置为800，400扩增设置为200
- `files_per_bar` 如果input_fastq为包含多个barcode的 fastq_pass文件夹，则规定每个barcode文件夹中最少有`files_per_bar`个fastq文件，如果少于该值，则不分析这个样本。用于应对barcode拆分错误，unclassfied文件夹不分析

2. `snpEff.config` snpEFF软件的配置配置文件

env

artic-lie.env.yaml：创建`artic-like`的env.yaml文件，`conda env create -f artic-lie.env.yaml`会创建artic-like环境

genome

snpEff软件`-dataDir`的参数。文件夹里包含了以可以分析的样本类型命名的文件夹。如`sars-cov-2`。每个文件夹里包含的文件如下：

```
sars-cov-2/
├── genes.gff
├── sequences.fa
├── sequences.fa.fai
└── snpEffectPredictor.bin
```

> - `genes.gff` 为变异注释文件
> - `sequences.fa` 为参考基因组文件
> - `sequences.fa.fai` 为分析时自动生成的索引文件，可以忽略
> - `snpEffectPredictor.bin` 为使用snpEff进行注释之前要构建的一个文件，注释需要，需要手动生成

如果后续增加了`other_virus`或者其他病毒的信息，则需要在该文件夹下新建一个以`other_virus`命名的文件夹，并在`other_virus`下保存`sequences.fa`基因组文件和可选的（`genes.gff`、`snpEffectPredictor.bin`）文件，还需要修改在`config/snpEff.config`中增加`some_virus`的信息（可参考这里）

scripts

分析过程中使用到的一些脚本

1. `nano_filter_vcf.py` 根据深度、质量值等过滤longshot输出的vcf文件
2. `nano_handle_snpeff_results.py` 从注释vcf文件中提取信息，用于报告展示
3. `nano_mask_reference.py` 将参考基因组上低质量的位点标记为N
4. `nano_plot.py` 覆盖深度作图，当某一位点深度大于1200时将其修改为1200，所以图中显示最大深度即为1200
5. `nano_report.py` 生成pdf报告的tex源文件
6. `nano_trim_align.py` 如果指定引物的话，会使用该脚本从比对后的bam文件中修改比对record，在alignment trim掉引物区域的比对，使其比对位置从前引物末端 开始 到 后引物起始位置 结束
7. `nano_trim_primer_DISCARDED.py` 已废弃

Snakefile

比对的流程及需要执行的shell脚本都包含在该文件中，Snakemake命令默认会在当前目录下寻找`Snakefile`或`snakefile`。或者通过命令行指定snakefile：`--snakefile path/to/specified/snakefile`

texlive

打包的一个texlive软件，用于编译tex文件输出pdf报告

输出文件说明

默认情况下会在当前文件夹下输出`test001`，通过`--config analysis_name=barcode03`可以将输出文件夹指定为`barcode03/barcode03`，其目录结构如下：

```
4.0K drwxrwxr-x 2 a a 4.0K 4月  11 01:03 aligns
4.0K drwxrwxr-x 2 a a 4.0K 4月  11 01:02 clean_data
4.0K drwxrwxr-x 2 a a 4.0K 4月  11 01:03 consensus
4.0K drwxrwxr-x 2 a a 4.0K 4月  11 01:03 depth
4.0K drwxrwxr-x 2 a a 4.0K 4月  11 01:03 figures
4.0K drwxrwxr-x 2 a a 4.0K 4月  11 01:03 nanoplot
4.0K drwxrwxr-x 2 a a 4.0K 4月  11 01:03 pangolin
4.0K drwxrwxr-x 2 a a 4.0K 4月  11 01:03 report
4.0K drwxrwxr-x 2 a a 4.0K 4月  11 01:03 stat
4.0K drwxrwxr-x 2 a a 4.0K 4月  11 01:03 variants
```

1. `aligns` 各种比对文件有raw.bam、sorted.bam和primer_trimmed.bam\
   - `raw.bam` 最原始的bam文件，保留了所有的比对
   - `sorted.bam` 去除了一些低质量比对，并排序
   - `primer_trimmed.bam` 如果有引物信息（config.yaml中指定了primer_bed参数），原始数据进行fastp过滤时，不进行read的两端的trim，直接进行比对，之后按照引物位置进行alignment Trim，得到primer_trimmed.bam。如果没有引物信息，原始数据进行fastp过滤时，首先根据长度进行过滤，然后再将得到的read进行比对，再从alignment两端进行一定碱基数量的trim，之后挑取一些mapQ大于指定值的alignment，得到primer_trimmed.bam
2. `clean_data` 根据读长和质量值过滤后输出的clean.data.fastq.gz
3. `consensus` 输出一致性序列

4. `fuigures` 覆盖深度统计图
5. `depth` 输出每个位点的覆盖深度，per-base.depth为每个点的覆盖深度，low_coverage.bed时从per-base.depth中挑出的深度低于`{min_dp}`的位置
6. `nanoplot` NanoPlot输出的一些统计信息和图片
7. `pangolin` 新冠样本会使用pangolin进行一个分型分析，结果保存在这里，如果没有`snakemake annotate` 则不会生成该目录
8. `report` 输出的报告
9. `stat` 进行的一个简单统计，包括原始数据量和read数以及比对到参考基因组（aligns目录下的primmer_trimmed.bam）上的数据量和read条数
10. `variants` 分析过程中产生的变异文件以及注释文件
    - `{SAMPLE}.fail.vcf.gz` 一些深度较低或者QUAL较低，或者一些杂合位点（het_sites设置为"more"）或者一些移码突变的位点（frameshifts设置为0）,这些位置会被设置为N
    - `{SAMPLE}.pass.vcf.gz` bcftools consensus会使用这个文件输出consensus序列，apply alt, ignore genotype
    - `{SAMPLE}.longshot.ann.vcf` longshot注释得到每个等位基因的深度
    - `{SAMPLE}.report.vcf` `{SAMPLE}.report.snpEff.annotate.vcf`报告会输出这个文件中的变异位点
    - `{SAMPLE}.report.snpEff.annotate.txt` 报告中输出的变异位点列表，tab键分隔
    - `{SAMPLE}.medaka.vcf` 从`{SAMPLE}.medaka.gvcf.gz`中过滤得到的变异位点，排除这些位点：ALT="." || QUAL < {MIN_QUAL}

针对该流程的snakemake简单说明和使用示例

snakemake是一个用来进行生信分析流程搭建和管理的软件，可以和python无缝衔接。snakemake默认情况下会在当前目录寻找是否有`snakefile`或者`Snakefile`从而解析其中的分析流程。可以通过命令行指定`config.yaml`文件或者在`Snakefile`中指定`config.yaml`文件，从而向分析流程中传递参数，以artic-like为例，首先激活artic-like环境 conda activate artic-like

snakemake 使用时必需指定--cores 参数

1. 在artic-like目录下进行分析（**常用**）。执行以下命令即可完成分析

```
snakemake consensus --cores all --config
input_fastq=/the/path/to/input_fastq analysis_name=today min_read_len=800
max_read_len=1500 primer_bed=/the/path/to/primer.bed --directory ~/Desktop

snakemake annotate --cores all --config
input_fastq=/the/path/to/input_fastq analysis_name=today min_read_len=800
max_read_len=1500 primer_bed=/the/path/to/primer.bed --directory ~/Desktop

snakemake all --cores all --config input_fastq=/the/path/to/input_fastq
analysis_name=today min_read_len=800 max_read_len=1500
primer_bed=/the/path/to/primer.bed --directory ~/Desktop

# snakemake consensus 用于生成一致性序列，
# input_fastq修改config/config.yaml中的input_fastq值，
# analysis_name指定分析名称，会在--directory参数，及在~/Desktop下创建名为
{analysis_name}的目录。如果input_fastq中包含barcode01、barcode02、barcode03等多
个样本，则会在~/Desktop/{analysis_name}下创建名为barcode01、barcode02、barcode03
的文件夹，每个样本的输出结果输出到对应的文件夹中；若 input_fastq里仅包含fastq文件，则将
结果输出到~/Desktop/{analysis_name}/{analysis_name}中
```

```
# min_read_len 和 max_read_len 用于修改config/config.yaml 中的min_read_len 和 max_read_len参数
# primer_bed 可选，已知引物信息则指定，未知则无需指定
# config/config.yaml文件中的所有参数都可以通过在命令行中，跟在--config中 以 param_name=value 的形式进行修改
# --directory 用于指定将结果输出到哪个目录中，如果不指定则为当前目录

# snakemake annotate 用于对结果进行注释，分型等，所有参数与consensus 一致

# snakemake report 用于生成pdf报告，所有参数与consensus 一致
```

2. 在任意目录下进行分析

```
snakemake consensus --cores 16 --snakefile /the/path/to/artic-like/Snakefile  --config input_fastq=/the/path/to/input_fastq

snakemake annotate --cores 16 --snakefile /the/path/to/artic-like/Snakefile  --config input_fastq=/the/path/to/input_fastq

snakemake report --cores 16 --snakefile /the/path/to/artic-like/Snakefile  --config input_fastq=/the/path/to/input_fastq

# 通过--snakefile 指定artic-like中的Snakefile即可在任意目录下使用artic-like流程
```

3. 一步执行

```
snakemake all --cores 12 --config input_fastq=/the/path/to/input_fastq analysis_name=test2
# 使用12个cores
# snakemake all 会一步执行完consensus、annotate、report三步命令，将结果输出到当前文件夹下./test2/test2 中
```

TODO List

1. 杂合位点设置为深度较高的等位基因或者不考虑深度，默认为alt，或者强制为N